



UNIVERSIDAD
AUSTRAL | INGENIERÍA

Plan de Trabajo Final

Navegación Autónoma de Drones Urbanos con Visión Monocular y SLM

Alumno: Jorge Enrique NICOLAU

Director: Rodrigo DEL ROSSO
Codirector: Ezequiel Omar NUSKE

02-07-2025

Resumen

La navegación autónoma de drones en entornos urbanos complejos, como Buenos Aires, enfrenta desafíos significativos debido a su infraestructura densa, obstáculos dinámicos y condiciones de iluminación variables, además de la escasez de conjuntos de datos locales adaptados. Las soluciones existentes a menudo son costosas o no están optimizadas para hardware de bajo costo, lo que limita su implementación práctica en contextos latinoamericanos y la capacidad de cumplir con regulaciones locales como las de la ANAC. Este trabajo busca superar estas limitaciones. Para abordar estos retos, se desarrolla un pipeline para la navegación autónoma de cuadricópteros eVTOL con visión monocular, diseñado específicamente para ser ejecutado en hardware de bajo costo. El sistema propuesto integra un Modelo de Lenguaje Ligero para la planificación de trayectorias previas al vuelo utilizando datos públicos. Para la navegación reactiva en tiempo real, se emplea un Modelo de Aprendizaje Ligero, que procesa las salidas de modelos de visión por computadora ligeros como YOLOv8n (detección de obstáculos), MobileNetV3+U-Net (segmentación semántica) y ORB-SLAM2 (SLAM visual) para generar comandos específicos de control. El desarrollo y la validación se realizan en AirSim (basado en Unreal Engine), utilizando un entorno virtual 3D personalizado de Buenos Aires generado a partir del uso de RealityCapture, OpenStreet Maps y Blender, y un dataset mixto que incluye videos públicos de YouTube. Se realiza una evaluación comparativa del SLM frente a Máquinas de Estados Finitos (FSM), estándar en pilotos automáticos, analizando su desempeño en métricas clave como la tasa de éxito de misión, el tiempo de reacción y el consumo computacional en escenarios simulados. Este trabajo contribuye con una solución accesible y escalable para ciudades latinoamericanas, aplicable en áreas como la logística de última milla, la inspección de infraestructura y la gestión de emergencias urbanas. La optimización para hardware de bajo costo como el Jetson Nano y el uso de herramientas abiertas reducen la dependencia de equipos costosos, facilitando la implementación de drones autónomos en la región y proporcionando un análisis novedoso sobre la viabilidad del SLM frente a las FSM en entornos con recursos limitados.

Palabras claves

*Navegación Autónoma de Drones | Entornos Urbanos | Visión Monocular
| Hardware de Bajo Costo | Modelo de Aprendizaje Ligero (SLM) |
Simulación en AirSim*

1. Problema de investigación

El problema central que se busca abordar es el desarrollo de capacidades de navegación autónoma de drones en entornos urbanos, un desafío de alta complejidad técnica y operativa que involucra múltiples dimensiones interdependientes. A diferencia de los espacios abiertos o rurales, donde los márgenes de maniobra son amplios y los riesgos relativamente acotados, el entorno urbano presenta un conjunto de condiciones únicas: alta densidad de obstáculos fijos (como edificios, puentes o postes), presencia de infraestructuras críticas (líneas eléctricas, hospitales, aeropuertos), y una multiplicidad de actores móviles — vehículos, peatones, bicicletas, maquinaria— cuya posición y trayectoria cambian constantemente. En este contexto, garantizar la seguridad de terceros y de los bienes materiales se vuelve una condición ineludible. Un dron que carezca de una percepción precisa y una capacidad de decisión robusta representa un riesgo tangible: puede colisionar, caer en zonas sensibles o interferir con otras operaciones, generando consecuencias potencialmente graves tanto desde el punto de vista humano como económico.

La percepción del entorno es uno de los pilares más críticos. Las ciudades afectan significativamente la calidad de los sensores: los edificios altos degradan o distorsionan la señal GPS, superficies metálicas o vidriadas generan falsas lecturas en sensores ópticos o LIDAR, y la detección de obstáculos móviles imprevistos —como una grúa en movimiento o un peatón emergiendo entre autos— requiere algoritmos de detección y seguimiento extremadamente eficientes. Un dron urbano debe ser capaz de construir, mantener y actualizar en tiempo real un mapa tridimensional confiable, que no solo represente con fidelidad el entorno, sino que también distinga entre objetos estáticos y dinámicos, incluso con datos incompletos o ruidosos.

Pero la autonomía va mucho más allá del simple vuelo automático. Implica planificación dinámica bajo incertidumbre, toma de decisiones ante eventos inesperados, elevada eficiencia energética, cumplimiento normativo y respuesta ante fallas, todo esto operando sobre hardware con restricciones computacionales y en condiciones sin supervisión humana directa.

La integración al espacio aéreo urbano suma una capa adicional de complejidad. A medida que el número de drones crezca, será imprescindible evitar colisiones y congestión aérea mediante mecanismos de identificación, comunicación y coordinación entre vehículos. En este punto, el rol de los organismos reguladores —como ANAC— será clave para equilibrar la innovación tecnológica con los estándares de seguridad.

Ciberseguridad y tolerancia a fallos son aspectos estratégicos. Los drones pueden ser blanco de ataques o sufrir errores técnicos. Se

requieren arquitecturas resilientes, capaces de detectar anomalías, operar en modo degradado y recuperarse automáticamente. En conjunto, garantizar una navegación autónoma urbana segura y eficiente demanda la integración sinérgica de percepción, control, regulación, ciberseguridad y diseño robusto.

El problema de la navegación autónoma de drones se agrava considerablemente en zonas urbanas densamente pobladas y en proceso de expansión. Estos entornos van desde centros metropolitanos con edificios altos que generan distorsiones en las señales GPS, un fenómeno detallado por Samy et al. (2019), hasta áreas residenciales con presencia de obstáculos variados como árboles, cables eléctricos, peatones y vehículos en constante movimiento. El desafío también se presenta en zonas cercanas a infraestructuras críticas, como aeropuertos u hospitales, donde el espacio aéreo suele estar congestionado o estrictamente regulado. Además, en contextos de emergencia o catástrofe, la infraestructura puede encontrarse dañada o fuera de servicio, lo que complica aún más la operación segura de drones.

En todos estos casos, una navegación autónoma deficiente no solo compromete el éxito de la misión, sino que conlleva riesgos graves y diversos: colisiones, daños materiales, lesiones a personas o incluso pérdidas fatales. Estos incidentes no solo afectan la seguridad pública, sino que también erosionan la confianza social en estas tecnologías emergentes. Como consecuencia, podrían intensificarse las restricciones regulatorias, encarecerse los seguros de operación, reducirse las inversiones, y dificultarse la viabilidad comercial de los servicios basados en drones. Más allá del riesgo físico, la pérdida de control de un dron puede comprometer la privacidad, la ciberseguridad o incluso derivar en daños estructurales, como ilustra el caso “Alarm as estate agent’s drone crashes into house - Property Industry Eye (s. f.)”.

Este panorama es aún más preocupante si se considera el crecimiento proyectado del uso de drones urbanos en diversas aplicaciones. Desde la logística de última milla, como señala Miranda et al. (2021), hasta la inspección de infraestructuras críticas que proponen Langåker et al. (2021) y tareas de seguridad urbana con herramientas como las de Xu et al. (2024), la proliferación de aeronaves no tripuladas en ciudades introduce una nueva capa de complejidad en la gestión del espacio aéreo tridimensional. A pesar de los avances tecnológicos en sensores, inteligencia artificial y autonomía, persisten desafíos significativos en la fusión de datos multisensoriales, la detección y evasión de obstáculos dinámicos, y la resiliencia frente a interferencias o fallos técnicos. Todo esto ocurre en un contexto donde el marco regulatorio internacional aún está en formación, y la forma en que evolucionará dependerá en gran medida de cómo se gestionen los

incidentes y se construya la gobernanza de riesgo en torno a estas tecnologías.

La navegación autónoma de drones representa una solución innovadora y eficaz para diversos desafíos que enfrenta la empresa agroexportadora donde trabajo, especialmente en tareas críticas como la inspección de carga en terminales portuarias, elevadores de granos y plantas procesadoras. Esta tecnología no solo resuelve problemas operativos actuales, sino que también abre la puerta a nuevas oportunidades de eficiencia, seguridad y optimización de datos.

En el caso de la inspección portuaria y en elevadores, las tareas manuales para revisar silos, bodegas de embarcaciones o depósitos verticales suelen ser peligrosas, lentas y de precisión limitada. Los drones autónomos, al operar rutas predefinidas sin intervención humana, permiten ingresar con facilidad a espacios confinados o de difícil acceso, minimizando riesgos laborales como caídas o exposición a sustancias nocivas. Equipados con cámaras de alta resolución, sensores térmicos o LiDAR, estos drones son capaces de detectar puntos calientes, zonas húmedas o fallas estructurales, y estimar volúmenes de grano con mayor exactitud que la inspección humana. Este enfoque no solo mejora la calidad de los datos, sino que también acelera el proceso: horas de inspección manual se convierten en minutos de operación automatizada.

La empresa donde me desempeño opera la planta de molienda de soja más grande del mundo, con capacidad para procesar 20.000 toneladas diarias desde su inauguración en 2014 (Infocampo (s. f.)). Además, cuenta con un puerto propio, almacenamiento para 310.000 toneladas de soja y 60.000 toneladas de aceite, y la posibilidad de recibir 1.000 camiones al día. En un entorno de esa magnitud, los drones autónomos pueden ejecutar patrullajes programados para identificar desgastes prematuros en maquinaria o detectar anomalías térmicas, habilitando estrategias de mantenimiento predictivo y previniendo interrupciones productivas costosas.

Además, la navegación autónoma aporta valor en la gestión de inventario, permitiendo la medición precisa de volúmenes mediante tecnologías como fotogrametría o LiDAR (UMILES GROUP (2024)). Su utilidad se extiende también a la etapa agrícola: el monitoreo de cultivos para detectar plagas o deficiencias nutricionales con intervención temprana impacta positivamente en la calidad del grano exportado (Castro et al. (2020)). La vigilancia perimetral autónoma añade otra capa de seguridad operacional.

Integrar esta tecnología no solo reduce riesgos y mejora la eficiencia, sino que otorga una ventaja competitiva real, como demuestran experiencias exitosas como la de “Drone Silo Inspections - Case Study - Horus Drones (s. f.)”.

La propuesta para la navegación autónoma de drones en entornos urbanos se basa en la integración jerárquica de Grandes Modelos de Lenguaje (LLM) y Modelos de Lenguaje Pequeños (SLM) para la planificación estratégica y la toma de decisiones tácticas. Esta arquitectura se valida mediante simulaciones realistas generadas a partir de entornos urbanos capturados en la ciudad de Buenos Aires, diferenciándose notablemente de los enfoques tradicionales. El objetivo no solo es aumentar la autonomía, sino hacerlo con eficiencia de costos y accesibilidad de hardware, factores clave para su escalabilidad práctica.

La innovación principal está en reemplazar las clásicas Máquinas de Estados Finitos (FSM), ampliamente utilizadas en pilotos automáticos por su predictibilidad, pero también por su rigidez ante situaciones imprevistas. Aunque las FSM siguen siendo útiles, como lo demuestra Hoang et al. (2024) en un caso aplicado, su naturaleza determinista limita su adaptabilidad. En contraste, los LLM aportan una capa de razonamiento contextual que permite interpretar misiones complejas y descomponerlas en subtarefas lógicas, tal como argumentan Zhu et al. (2024). Esto habilita, por ejemplo, que un dron entienda comandos de alto nivel como “patrullar perímetro y detectar actividad inusual”, y derive acciones específicas de navegación sin requerir una programación explícita previa.

Un rasgo distintivo de esta propuesta es su énfasis en el uso de hardware estándar, privilegiando la visión monocular sobre sensores costosos como el LiDAR (como describe Aldao et al. (2022)). Esto reduce la barrera de entrada y permite que los drones operen con un sistema de percepción asequible, aunque implica el desafío técnico de extraer geometría 3D solo a partir de cámaras RGB.

Para el control reactivo y la traducción de las instrucciones del LLM a acciones de vuelo precisas, se plantea utilizar SLM, por su eficiencia y baja latencia. Modelos como las redes neuronales líquidas, propuestas por Chahine et al. (2023), son una opción viable para esta capa de control. La combinación LLM+SLM permite una coordinación inteligente entre planificación semántica y ejecución rápida, gestionando mejor la incertidumbre incluso con visión monocular.

La validación de este enfoque se realiza mediante un pipeline que emplea RealityCapture y Blender para construir entornos virtuales en AirSim, basados en videos de drones reales de Buenos Aires. Al utilizar Unreal Engine, AirSim ofrece simulaciones fotorrealistas y físicas precisas, lo cual fortalece la confiabilidad de las pruebas. Este uso de gemelos digitales urbanos es metodológicamente sólido y especialmente relevante al depender de percepción visual. La propuesta no solo combina innovación algorítmica y eficiencia en hardware, sino que se sustenta en una validación rigurosa que acerca la teoría a la práctica.

2. Solución al Problema Identificado

El presente trabajo propone un pipeline completo y modular para la navegación autónoma de drones en entornos urbanos simulados, que abarca desde la adquisición y procesamiento de datos reales hasta la evaluación comparativa entre distintas estrategias de control, incluyendo Máquinas de Estados Finitos (FSM) y enfoques híbridos basados en modelos de aprendizaje automático. Esta arquitectura integra visión por computadora, simulación fotorrealista y modelos livianos, con énfasis en la reproducibilidad, escalabilidad y apertura de código, facilitando su extensión en investigaciones académicas o aplicaciones industriales. Parte del enfoque toma inspiración de trabajos como el de Goel et al. (2021) en visión por computadora, y se valida dentro de simuladores avanzados como AirSim, basado en Unreal Engine (Shah et al. (2017); Matej (2016)).

El pipeline está dividido en dos grandes componentes. El primero corresponde a la digitalización de entornos urbanos a partir de videos públicos de Buenos Aires (por ejemplo de YouTube). A partir de estos, se extraen frames en secuencia que son filtrados para asegurar diversidad visual: distintas zonas geográficas, condiciones de iluminación y densidad urbana. La anotación de obstáculos y zonas seguras de aterrizaje se realiza con LabelImg y LabelMe, respectivamente. Luego, los modelos 3D hiperrealistas son generados con RealityCapture y optimizados en Blender para reducir complejidad computacional. Estos modelos se importan en AirSim, lo que permite realizar simulaciones con realismo físico y visual, crucial para validar algoritmos de navegación.

El segundo pipeline se enfoca en la navegación autónoma dentro del entorno simulado. Para ello se emplea una companion computer (simulada vía Docker como una Jetson Nano con NVIDIA L4T) conectada a un entorno SITL (Software-in-the-Loop) usando MAVLink como protocolo de comunicación (ver Koubaa et al. (2019)). AirSim genera los datos sensoriales (cámara monocular, IMU, GPS) y los transmite al controlador PX4 emulado en Docker (Aliane (2024)), que a su vez interactúa con la companion computer.

Dentro de la Jetson Nano simulada, se ejecutan algoritmos de navegación como SLAM para mapeo y localización simultánea, y detección de objetos en tiempo real usando YOLO (Redmon et al. (2015)), empleando imágenes RGB simuladas. Los resultados se integran para alimentar modelos de control: una FSM simulada por PX4, un Modelo Liviano (SML), o un LLM para planificación de misiones. Este esquema permite comparar estrategias reactivas, basadas en estados, con enfoques cognitivos adaptativos, integrando visión, lenguaje y simulación de forma coherente.

Además, la solución propuesta aborda el desafío de la navegación autónoma de drones en entornos urbanos densos mediante la implementación de un sistema para eVTOL cuadricópteros, basado exclusivamente en visión monocular y hardware de bajo costo, como el Jetson Nano, lo cual lo hace viable en contextos con restricciones económicas y sin infraestructura especializada. Inspirada en trabajos previos sobre navegación urbana autónoma, como el de Castelli et al. (2016), esta propuesta se centra en adaptar dichas tecnologías al entorno específico de la ciudad de Buenos Aires, caracterizado por su alta densidad urbana y diversidad estructural.

Para lograr esto, el sistema se entrena utilizando un conjunto híbrido de datos que combina videos públicos de la ciudad con simulaciones tridimensionales generadas mediante herramientas como RealityCapture, OpenStreetMap (OSM) y Blender, siguiendo métodos de reconstrucción similares a los descritos por Li et al. (2022) en trabajos de fotogrametría urbana. Estos datos se integran en un pipeline reproducible sobre el simulador AirSim, lo que permite validar el sistema de navegación en escenarios urbanos realistas, con simulaciones fotorrealistas y física controlada, garantizando así una evaluación robusta antes del despliegue físico.

En cuanto a la lógica de control, se comparan dos enfoques: por un lado, Máquinas de Estados Finitos (FSM), un enfoque clásico y determinista utilizado extensamente en vehículos autónomos (como se observa en Hu et al. (2024)); y por otro, Modelos de Lenguaje Pequeños (SLM), que ofrecen mayor flexibilidad, aprendizaje contextual y capacidad de adaptación. Esta comparación se realiza específicamente en tareas como detección de obstáculos, mapeo SLAM y aterrizaje autónomo, evaluando el desempeño en términos de precisión, eficiencia computacional y latencia, bajo las limitaciones de una plataforma Jetson Nano y utilizando exclusivamente datos de cámaras monoculares.

El uso de cuadricópteros, en lugar de vehículos de ala fija, responde a la necesidad de maniobrabilidad y simplicidad operativa en entornos urbanos estrechos y dinámicos. Esta elección también se alinea con las regulaciones locales de espacio aéreo, como las establecidas por la Resolución ANAC - Reglamento de Vehículos Aéreos No tripulados (2019), lo cual refuerza la aplicabilidad práctica del sistema en contextos reales.

El desarrollo se limita al uso exclusivo de datos públicos, como videos de drones en Buenos Aires disponibles en plataformas como YouTube: a partir de esto se generan los escenarios de simulación. Las pruebas del sistema se realizarán emulando el comportamiento del Jetson Nano conectado a un dron en AirSim. Las tareas principales incluyen detección de obstáculos mediante YOLO, segmentación semántica para aterrizaje y mapeo con ORB-SLAM2 (presentado en Mur-Artal et al.

(2015)). Es decir, tanto el entrenamiento como la simulación que valida la solución son virtuales.

Está fuera del alcance de este trabajo, pero el siguiente paso del proyecto consiste en probar el modelo de navegación autónoma desarrollado en una placa Jetson Nano real (seleccionada por ser un SoC con una GPU, ver NVIDIA (2025)), con el objetivo de validar las limitaciones identificadas en las simulaciones realizadas en AirSim y evaluar el rendimiento del sistema en un entorno de hardware embebido de bajo costo. Esta etapa permitirá medir métricas reales, como latencia de inferencia, consumo computacional (FPS) y uso de memoria, para YOLOv8n, ORB-SLAM2, y el SLM, bajo las restricciones del hardware Jetson Nano. La validación en hardware confirmará si las optimizaciones aplicadas (posiblemente inferencia con TensorRT en video con resolución 320x240) son suficientes para cumplir con los requisitos de tiempo real en un contexto urbano como Microcentro, Buenos Aires, y proporcionará una comparación directa con los resultados simulados, identificando posibles discrepancias debidas a las idealizaciones de AirSim, como la ausencia de ruido de sensores o variaciones de iluminación.

Tras validar el modelo de navegación autónoma en una placa Jetson Nano para confirmar su rendimiento en hardware embebido, el siguiente paso consiste en conectar la Jetson Nano como companion computer a un dron, como el del kit Holybro X500 V2 (pensado para experimentos modulares con drones X500 V2 Kits (s. f.)), equipado con una cámara monocular a bordo, como la Raspberry Pi Camera V2. Esta integración permitirá ejecutar el pipeline completo (YOLO, ORB-SLAM2 y SLM) en un entorno real, procesando datos de la cámara en tiempo real para navegación autónoma en escenarios urbanos como Microcentro, Buenos Aires. La Jetson Nano, optimizada con TensorRT, se comunicará con el controlador de vuelo del dron (en el stack planteado PX4, “Open Source Autopilot for Drones - PX4 Autopilot (s. f.)”) para enviar comandos de navegación basados en las salidas del modelo, permitiendo evaluar el comportamiento del sistema frente a condiciones reales, como ruido de sensores, variaciones de iluminación y dinámica de vuelo, y compararlo con los resultados obtenidos en las simulaciones de AirSim.

3. Aplicaciones prácticas

La solución propuesta para la navegación autónoma de drones en entornos urbanos plantea un conjunto de utilidades que responden a desafíos críticos tanto en el ámbito de la agroexportación como en aplicaciones urbanas generales, contribuyendo a una transformación profunda de las capacidades operativas aéreas en distintos sectores. El valor central de esta tecnología radica en su capacidad para operar sin intervención humana directa, lo que permite eliminar la exposición a riesgos físicos, reducir errores humanos y asegurar una operación continua y eficiente en condiciones adversas o de difícil acceso. Esta autonomía no solo mejora la eficiencia de recursos y la productividad, sino que también promueve el avance tecnológico en campos como la inteligencia artificial, la visión por computadora y la robótica aplicada.

En el sector agroexportador, la navegación autónoma de drones resulta particularmente útil en operaciones de inspección, mantenimiento y control logístico. En terminales portuarias y elevadores de granos, los drones pueden ejecutar recorridos programados para inspeccionar silos y bodegas de barcos, detectando puntos de calor que indican humedad o deterioro y estimando volúmenes con alta precisión, sin poner en riesgo al personal humano. En plantas procesadoras, como la mayor planta de molienda de soja del mundo, con una capacidad de procesamiento de 20.000 toneladas diarias según Infocampo (s. f.), los drones permiten detectar desgastes prematuros en equipos, habilitando esquemas de mantenimiento predictivo que previenen interrupciones productivas. También aportan a la gestión de inventario mediante tecnologías como LiDAR o fotogrametría, alcanzando una precisión de medición detallada, tal como detalla UMILES GROUP (2024). Por otro lado, su capacidad para realizar vigilancia perimetral en instalaciones industriales o portuarias refuerza los protocolos de seguridad, al detectar intrusiones en tiempo real.

En contextos urbanos, la solución encuentra aplicaciones diversas. En la logística de última milla, permite a drones planificar rutas eficientes en ciudades densas como Buenos Aires mediante el uso de un LLM para el diseño de trayectorias y un SLM para la navegación reactiva en tiempo real, utilizando hardware de bajo costo como el Jetson Nano (NVIDIA (2025)). En la inspección de infraestructura urbana, los drones pueden navegar entornos complejos utilizando visión monocular, lo que reduce los costos asociados al uso de sensores más avanzados. Frente a emergencias, como desastres naturales o incendios, el sistema ofrece capacidades de planificación de rutas y navegación autónoma robusta, como lo describe Pestana Puerta (2017) para la logística de emergencia y Madridano Carrasco (2020) en el control de incendios mediante enjambres coordinados. Este enfoque contribuye a reducir riesgos humanos y optimizar la intervención en situaciones críticas.

La investigación en navegación autónoma de drones y vehículos aéreos no tripulados (UAVs), sustentada en visión artificial y fusión de datos, está transformando la forma en que se abordan tareas de alta complejidad operativa, alto costo o riesgo humano elevado. Las aplicaciones prácticas de estos sistemas son múltiples y se extienden a sectores críticos como la seguridad, la energía, la agricultura, la logística y la respuesta ante emergencias. Al automatizar tareas antes reservadas a operadores humanos, se consigue no solo mayor precisión y continuidad operativa, sino también una importante reducción de riesgos personales y de costos estructurales.

Una de las aplicaciones más relevantes es la intervención en entornos peligrosos. Mediante sensores embarcados y navegación autónoma, los UAVs pueden operar en áreas contaminadas o de difícil acceso, reduciendo drásticamente la exposición humana. El estudio de Martin et al. (2017) demuestra esta utilidad al utilizar drones equipados con sensores de radiación para mapear zonas contaminadas en instalaciones nucleares. En Sellafield, los UAVs volaron rutas autónomas registrando datos GPS, altitud mediante LiDAR y espectrometría gamma, lo que permitió generar mapas precisos de radiación sin riesgo para los operadores. Este tipo de aplicación es extensible a escenarios industriales, de defensa o desastres naturales.

Además de la mitigación de riesgos, la automatización aérea ofrece una mejora significativa en la eficiencia operativa. En contextos civiles, como el mantenimiento de infraestructuras, los UAVs han demostrado ser una alternativa eficaz. Langåker et al. (2021) presentan un sistema autónomo de drones para inspecciones en subestaciones eléctricas, donde los equipos operan desde hangares automatizados, sin intervención humana directa, capturando imágenes térmicas y visuales que son analizadas posteriormente en la nube. Esto reduce tanto los costos como los tiempos de inspección y permite un monitoreo más frecuente y confiable.

En paralelo, la posibilidad de operar en entornos sin señal GPS amplía las capacidades operativas de los UAVs. Empleando visión artificial y algoritmos de fusión de datos, los drones pueden realizar navegación autónoma en escenarios urbanos caóticos o áreas sin cartografía previa. Giacomossi Jr et al. (2024) exploran esta capacidad en un sistema de búsqueda y rescate basado en enjambres de UAVs. Su propuesta incorpora mapas de probabilidad, búsqueda bayesiana y heurísticas como Hill Climbing para optimizar la localización de personas desaparecidas, incluso en ausencia de infraestructura de posicionamiento.

Finalmente, es de destacar el trabajo de Yang et al. (2025) ilustran la aplicación de UAVs en inspecciones de infraestructura civil, ampliando el potencial de esta tecnología para tareas repetitivas como el

seguimiento de cultivos, redes de distribución o estructuras verticales. Estas investigaciones consolidan el papel de la navegación autónoma como una herramienta clave para mejorar la seguridad, eficiencia y autonomía de operaciones en múltiples industrias, apoyada por tecnologías cada vez más accesibles y adaptables.

El desafío de la navegación autónoma en drones, especialmente en entornos urbanos densos o sin cobertura GPS, ha impulsado múltiples líneas de investigación que integran visión artificial, fusión de sensores, planificación algorítmica e inteligencia artificial. Estas soluciones avanzan en paralelo con desarrollos normativos que buscan garantizar la seguridad operativa de aeronaves no tripuladas. Desde trabajos pioneros en simulación, como el de Kemeny & Panerai (2003), hasta frameworks modernos basados en gemelos digitales, el campo ha evolucionado hacia arquitecturas más complejas, eficientes y contextualizadas.

Uno de los enfoques más influyentes es el de Castelli et al. (2016), quienes desarrollan un sistema híbrido para navegación segura a baja altitud en entornos urbanos, combinando planificación global con el algoritmo A* reforzado por datos GIS y replanificación dinámica ante obstáculos móviles. El sistema, probado en 54 simulaciones de misión, incrementó significativamente la distancia de seguridad frente a objetos en movimiento, utilizando mapas georreferenciados como base para generar trayectorias cargables en drones comerciales. Esta aproximación permite priorizar rutas sobre techos en lugar de calles, aumentando la seguridad del entorno urbano.

Complementando este enfoque, Hughes & Engelbrecht (2023) proponen una arquitectura multinivel para enjambres de UAV en escenarios urbanos tridimensionales. Mediante un modelo 3D de Manhattan, implementan planificación a largo plazo junto con esquemas cooperativos de evasión de colisiones que emplean estructuras de bounding volume hierarchies y diagramas de Voronoi, optimizando trayectorias en espacios congestionados.

En aplicaciones de respuesta ante desastres, Arnold et al. (2018) simulan un enjambre autónomo de UAVs para reconocimiento post-tsunami, mostrando que cinco drones pueden cubrir un área de 2 km² en menos de 90 minutos con estrategias como búsqueda espiral, scatter y formación reactiva. Este trabajo destaca la eficiencia de arquitecturas descentralizadas para mejorar la percepción situacional en emergencias reales.

El uso de gemelos digitales ha ganado protagonismo en simulaciones complejas. Turco et al. (2024) integran MATLAB y AirSim para modelar dinámicas de tráfico aéreo urbano, optimizando tanto sensores como comportamientos vehiculares. AirSim, basado en Unreal Engine, permite una simulación visual y física de alta fidelidad que resulta

clave para validar estrategias de evasión en condiciones realistas. En robótica terrestre, Da Silva et al. (2024) aplican ROS2 y Gazebo al robot TurtleBot3, incorporando sensores LIDAR y SLAM, sentando bases replicables para navegación autónoma terrestre.

En cuanto a movilidad aérea urbana, Nguyen et al. (2021) proponen corredores aéreos tridimensionales basados en GIS, donde los UAVs navegan rutas jerárquicas reguladas por una plataforma central. Este sistema emplea algoritmos de control por inversión de modelo y estructuras Markovianas para garantizar la continuidad operativa en entornos complejos y con débil señal GPS. Por su parte, Graf et al. (2021) abordan la planificación en tráfico urbano mediante optimización cuadrática, incorporando modos de emergencia para evasión ante amenazas dinámicas.

Estos avances se ven acompañados por cambios regulatorios en Argentina (Resolución ANAC - Reglamento de Vehículos Aéreos No tripulados, 2019), que establece el marco para integrar drones autónomos en el espacio aéreo urbano. Este marco prioriza la seguridad y permite el desarrollo tecnológico, fomentando aplicaciones de UAV tanto comerciales como científicas.

La propuesta se distingue por su enfoque innovador en la aplicabilidad de tecnologías de navegación autónoma para drones, priorizando la accesibilidad en contextos como el latinoamericano y, en particular, el argentino. Mientras muchos desarrollos en este campo dependen de soluciones de alto costo, como los sistemas basados en LiDAR utilizados por Aldao et al. (2022), o de arquitecturas adaptadas a entornos tecnológicos más sofisticados, este trabajo propone una alternativa viable, eficiente y reproducible que responde a las limitaciones reales de infraestructura, presupuesto y marco regulatorio de la región.

Una de las principales contribuciones del proyecto es la optimización de su arquitectura para hardware de bajo costo, específicamente el Jetson Nano. Esta decisión permite desplegar modelos como YOLOv8n y ORB-SLAM2 sin requerir GPUs de alto rendimiento, lo cual contrasta con propuestas como la de Nothdurft et al. (2011), que emplean sensores avanzados y costosos. El uso exclusivo de visión monocular plantea un desafío técnico importante, pero al mismo tiempo representa una ventaja crucial para la escalabilidad del sistema, especialmente en zonas donde la inversión inicial en hardware especializado no es viable.

Otro aspecto innovador es el desarrollo de un pipeline completo y reproducible de ciencia de datos, basado en la integración de datos reales y sintéticos. A partir de videos públicos de YouTube, se extraen secuencias de imágenes representativas de entornos urbanos de Buenos Aires, que luego se integran con modelos 3D generados a partir de

OpenStreetMap, RealityCapture, como en el trabajo de Li et al. (2022), y Blender. Esta recreación de escenarios urbanos se inserta en AirSim, el simulador de entornos realistas basado en Unreal Engine, desarrollado por Shah et al. (2017), lo que garantiza una validación rigurosa en condiciones de simulación visual y física de alta fidelidad.

Una tercera dimensión de originalidad es la evaluación comparativa entre dos estrategias de toma de decisiones: Máquinas de Estados Finitos (FSM), comúnmente utilizadas en control reactivo, y Modelos de Aprendizaje Ligerero (SLM), más adaptativos, pero con mayores requerimientos computacionales. La comparación se realiza específicamente en tareas de detección, aterrizaje y SLAM, en un contexto urbano denso como el de Buenos Aires, con hardware limitado y utilizando únicamente cámaras RGB. Esta experimentación concreta permite evaluar ventajas y limitaciones de cada enfoque, y contribuye con evidencia empírica a una discusión aún abierta en robótica aérea sobre el equilibrio entre eficiencia, robustez y adaptabilidad.

En suma, la propuesta ofrece una arquitectura viable, contextualizada y extensible, que promueve el desarrollo tecnológico autónomo en ciudades con recursos limitados, sin resignar calidad técnica ni rigor metodológico.

4. Transferencia de los resultados obtenidos

Para ampliar el trabajo presentado, se pueden explorar diversas líneas de desarrollo basadas en las limitaciones identificadas, manteniendo un enfoque realista y aplicable. En el controlador de navegación, una mejora posible es la incorporación de múltiples modelos especializados a lo largo de la trayectoria para mejorar la estimación de posición. Esto permitiría ampliar la cobertura y la precisión del sistema, adaptándolo a distintos escenarios complejos. También se podría complementar la visión monocular con cámaras laterales o visión binocular, así como añadir sensores de proximidad para optimizar la percepción del entorno, facilitar la coordinación en enjambres y mejorar la evasión de obstáculos. Para lograr un aterrizaje más preciso sin depender exclusivamente del GPS, la integración de sensores de altura por ultrasonido y modelos especializados puede ser una solución efectiva.

El concepto de utilizar múltiples modelos se refleja en el trabajo de F. Chen et al. (2014), donde se desarrolla un esquema adaptativo y reconfigurable para cuadricópteros que combina modelos fijos para fallos conocidos, modelos adaptativos para variaciones no previstas y un modelo que acelera la convergencia al identificar escenarios cercanos. Este enfoque modular mejora significativamente la resiliencia del control frente a fallos, superando a los esquemas tradicionales.

En cuanto al procesamiento de video, se sugiere investigar algoritmos avanzados para detección de puntos característicos y técnicas de supresión de fondo, como transformadas wavelet o filtros Retinex, para imágenes infrarrojas y con ruido, tal como proponen Marazzato & Sparavigna (2015). La descomposición de imágenes en sub-imágenes permitiría a submodelos especializados detectar objetos en ambientes complejos y ruidosos con mayor robustez.

La fusión combinada de imágenes en espectro visible e infrarrojo se aborda en el trabajo de Vipparla et al. (2024), que presenta DeepFusion, una solución basada en redes neuronales para integrar imágenes no calibradas, superando métodos tradicionales y ofreciendo métricas innovadoras para evaluar calidad de fusión.

Complementariamente, el uso de SLAM térmico, como en Shin & Kim (2019), mejora la navegación en condiciones adversas de baja visibilidad mediante la fusión de imágenes térmicas con mapas de profundidad escasa, proporcionando estimaciones robustas en oscuridad, humo o niebla.

Validar el sistema en hardware real es fundamental. Se recomienda probar la solución en una Jetson Nano conectada a AirSim, para luego implementarla en un dron físico como el Holybro X500 V2, permitiendo medir latencia, consumo y comportamiento ante ruido y condiciones cambiantes. La incorporación de aprendizaje por refuerzo en

el SLM podría dotar al dron de políticas de navegación más adaptativas y robustas frente a obstáculos dinámicos, ampliando así las capacidades del sistema autónomo.

Los avances en navegación autónoma basados en visión y hardware accesible no se limitan a drones cuadricópteros operando en entornos urbanos. La versatilidad y escalabilidad de estas tecnologías permiten su aplicación en una amplia gama de vehículos autónomos y sistemas robóticos en sectores diversos. Por ejemplo, los drones de ala fija se benefician de plataformas económicas que utilizan visión monocular para vuelos de larga duración y mayor alcance. Esto posibilita misiones críticas como la vigilancia ambiental, el monitoreo marítimo o el patrullaje fronterizo, donde la eficiencia energética y la autonomía prolongada son fundamentales. Estos sistemas incorporan modelos ligeros que optimizan la planificación de rutas y la evasión de obstáculos, como muestra el ensayo en drones de ala fija de Zhou et al. (2025).

En el ámbito marítimo, los barcos autónomos equipados con sensores visuales y algoritmos de navegación pueden desempeñar tareas de inspección portuaria, monitoreo de la calidad del agua y vigilancia costera sin necesidad de tripulación, aumentando la seguridad y reduciendo costos operativos. De forma similar, los submarinos autónomos aprovechan tecnologías de visión combinadas con sensores acústicos para la exploración subacuática, el mapeo del fondo marino y la detección de objetos en entornos donde el GPS no está disponible y la visibilidad es limitada. Un caso relevante es el estudio sobre ataque automático de naves presentado por Song et al. (2025).

Las sondas espaciales representan otro campo donde la navegación autónoma robusta y eficiente resulta indispensable. Procesar localmente datos de sensores e imágenes para planificar movimientos en entornos impredecibles y con latencias elevadas en la comunicación remota es crucial para misiones en planetas o asteroides. Plataformas que integran modelos ligeros de aprendizaje y visión adaptativa permiten a estos vehículos explorar superficies, evitar obstáculos y tomar decisiones en tiempo real, elevando la autonomía y seguridad de la misión. Un ejemplo destacado es la misión Clipper a Europa, luna de Júpiter, cuyo diseño y sistema de navegación se detallan en Cangahuala et al. (2025).

En la industria automotriz, los vehículos autónomos se benefician de algoritmos optimizados para hardware accesible y basados en visión monocular, facilitando la navegación en entornos urbanos y carreteras complejas. La combinación de modelos adaptativos de toma de decisiones y sistemas de percepción económicos amplía la accesibilidad tecnológica, especialmente en mercados emergentes donde la reducción de costos es esencial. La plataforma EMMA de Waymo, explicada en Hwang et al. (2024), es un caso representativo.

En todos estos escenarios, la construcción de plataformas económicas y extensibles basadas en visión y modelos ligeros de inteligencia artificial permite soluciones reutilizables y adaptables a diferentes vehículos y sectores, desde la exploración espacial hasta la logística urbana y la seguridad ambiental.

Objetivo del trabajo

- Objetivo general

Desarrollar un sistema de visión por computadora basado en visión monocular con capacidad de navegación autónoma de cuadricópteros eVTOL para aplicaciones varias como mantenimiento de infraestructuras, atender emergencias o realizar entrega expedita de paquetes, donde se requiera logística en entornos urbanos como el de Buenos Aires.

- Objetivo específico

Centrar la implementación de un pipeline reproducible, diseñado para ser ejecutado en el simulador AirSim (basado en Unreal Engine) a fin de validar el desempeño del sistema de navegación implementado.

- Objetivo específico

Integrar en el sistema tareas de detección de obstáculos, aterrizaje de precisión y mapeo mediante SLAM visual, utilizando modelos ligeros optimizados para hardware de bajo costo de modo de conseguir un caso de negocio viable para economías como la local.

- Objetivo específico

Evaluar el rendimiento de la solución del rendimiento de un modelo ligero de aprendizaje automático (SLM) frente a pilotos automáticos tradicionales basados en máquinas de estados finitos (FSM), utilizando métricas como tasa de éxito, tiempo de reacción y consumo computacional para determinar el mejor modelo de navegación autónoma.

5. Trabajos relacionados

Diversos trabajos han abordado el desafío de la navegación autónoma en drones, concentrándose en enfoques innovadores y aplicaciones específicas que abarcan desde algoritmos avanzados hasta entornos urbanos complejos. Un punto de partida relevante es el artículo de AlMahamid y Grolinger (2022), que ofrece una revisión sistemática del uso del Aprendizaje por Refuerzo (RL) en vehículos aéreos no tripulados (VANT). Este trabajo identifica tareas clave de navegación como el control de vuelo, la evasión de obstáculos, la planificación de rutas y la coordinación en enjambres. Además, clasifica los algoritmos de RL según sus características y aplicaciones, analiza herramientas y simuladores utilizados en la investigación, y destaca brechas y oportunidades para futuras exploraciones, sirviendo como guía para seleccionar métodos adecuados en la navegación autónoma de drones.

Por otro lado, Jwo et al. (2023) presentan una revisión detallada del empleo de redes neuronales artificiales (ANN) en sistemas de navegación, especialmente en la integración de sistemas inerciales (INS) y GNSS. Destacan que las ANN, pese a su naturaleza de “caja negra”, mejoran la precisión en entornos donde las señales satelitales pueden fallar, como las ciudades densas. Exploran arquitecturas diversas como redes de retropropagación, LSTM y GRU, y muestran cómo estas pueden superar las limitaciones de los filtros de Kalman tradicionales, especialmente en la fusión de datos y la compensación de errores. También discuten enfoques híbridos con lógica difusa y técnicas adaptativas, y señalan desafíos relacionados con la necesidad de grandes datos de entrenamiento y la adaptación en tiempo real.

Un enfoque temprano y pionero lo ofrece Castelli et al. (2016), con un sistema que combina imágenes georreferenciadas y datos de GIS para planificar rutas óptimas en entornos urbanos, utilizando el algoritmo A*. Su método pondera riesgos basándose en el uso del suelo y ajusta dinámicamente la trayectoria para evitar obstáculos móviles, optimizando la seguridad en tiempo real.

Más recientemente, Hughes y Engelbrecht (2023) desarrollan un sistema de navegación para múltiples VANT en entornos urbanos, integrando planificación de rutas a largo plazo y evasión cooperativa a corto plazo. Su simulación con modelos 3D reales y validación mediante Monte Carlo permite prever y evitar colisiones entre drones y con el entorno.

Finalmente, Bouhamed et al. (2020) aplican aprendizaje por refuerzo profundo (DDPG) para la planificación autónoma de trayectorias en drones, demostrando a través de simulaciones la capacidad del sistema para navegar en espacios tridimensionales complejos con

obstáculos estáticos y dinámicos, aprendiendo y adaptándose para evitar colisiones y alcanzar objetivos específicos.

Aunque algunos trabajos no se enfocan exclusivamente en la navegación autónoma de drones, su aporte en simulación y herramientas es crucial para el desarrollo e implementación efectiva de estos sistemas. Long (2024) sintetiza los principales desafíos en este campo y revisa el estado del arte, proporcionando una visión general indispensable para orientar futuras investigaciones y aplicaciones prácticas.

En un avance técnico importante, Li et al. (2024) presentan un sistema de SLAM visual para vehículos aéreos no tripulados que incorpora la detección y seguimiento de objetos dinámicos. Su innovación radica en la integración de una red neuronal de detección de objetos dentro del algoritmo SLAM, lo que permite identificar objetos en movimiento y construir un mapa tridimensional del entorno a partir de secuencias de imágenes. Para manejar múltiples objetos, el sistema combina la coincidencia semántica de regiones con técnicas de flujo óptico para asociar y rastrear dinámicamente los objetos detectados, mejorando la precisión y robustez en entornos complejos.

Turco et al. (2024) abordan la co-simulación como herramienta clave para el desarrollo y validación de sistemas de movilidad aérea avanzada y la gestión del tráfico de UAVs. Su estudio destaca la aplicación práctica de técnicas de co-simulación para crear algoritmos inteligentes de seguimiento de puntos de ruta y evasión de colisiones, contribuyendo a la seguridad y eficiencia operativa en entornos de tráfico aéreo autónomo.

Por su parte, Da Silva et al. (2024) se centran en la simulación de navegación autónoma en robótica móvil terrestre utilizando TurtleBot3 con ROS2 y Gazebo. Aunque el enfoque es terrestre, los principios fundamentales de detección de obstáculos mediante LIDAR y cámaras, junto con el mapeo del entorno, son plenamente transferibles a sistemas de navegación aérea. Además, destacan la capacidad de controlar vehículos aéreos autónomos mediante visión computacional, subrayando la convergencia tecnológica entre estos dominios.

Finalmente, Shah et al. (2017) desarrollaron AirSim, un simulador de alta fidelidad visual y física construido sobre Unreal Engine. Esta plataforma permite desarrollar y probar algoritmos para vehículos autónomos, incluidos cuadricópteros, en entornos realistas que combinan simulación física precisa con gráficos avanzados. AirSim ha sido fundamental para acelerar el desarrollo y la validación de sistemas autónomos, ofreciendo un entorno reproducible y controlado para experimentación.

En conjunto, estos estudios ofrecen un soporte integral para el avance de la navegación autónoma, combinando desarrollos en

percepción, control y simulación de alta fidelidad. No se limitan a proponer algoritmos innovadores, sino que también abordan la validación en entornos virtuales realistas, el seguimiento de objetos dinámicos, la planificación de trayectorias y la evasión de colisiones en condiciones complejas. Este enfoque multidisciplinario resulta clave para diseñar soluciones robustas, reproducibles y adaptables, especialmente en contextos donde la navegación sin GPS o con recursos computacionales limitados representa un desafío. Además, el uso de plataformas como AirSim y Gazebo permite replicar condiciones del mundo real sin los riesgos ni costos asociados a pruebas físicas, acelerando así el desarrollo de vehículos autónomos seguros. La convergencia entre robótica terrestre y aérea refuerza el potencial de estas tecnologías para escalar a múltiples dominios, desde la logística hasta la exploración.

La evolución en la comprensión y abordaje del problema central de la navegación autónoma en drones ha progresado desde modelos matemáticos clásicos hasta soluciones complejas diseñadas para operar en entornos dinámicos, donde la navegación sin GPS y la adaptabilidad a condiciones inciertas son requisitos clave. Un hito fundacional en esta trayectoria es el trabajo de Wahba (1965), quien formuló el conocido “problema de Wahba” para estimar la orientación de un satélite a partir de observaciones vectoriales relativas a un sistema de referencia. Este marco teórico sentó las bases para técnicas modernas de estimación de actitud utilizadas en vehículos espaciales y, por extensión, en sistemas aéreos no tripulados, permitiendo la fusión de datos sensoriales cuando no hay acceso a referencias absolutas como el GPS.

Décadas más tarde, Dickmanns (2024) retomó su enfoque de visión dinámica desarrollado en los años 80, utilizando modelos espaciotemporales (4D) para inferir posición y velocidad a partir de secuencias visuales. Esta técnica, basada en realimentación de errores predictivos, se implementó exitosamente en el sistema EMS-vision, que permitió conducción autónoma a alta velocidad durante el proyecto europeo PROMETHEUS. Su arquitectura jerárquica anticipó conceptos que hoy subyacen en sistemas de percepción modernos aplicados a drones, incluyendo aterrizajes autónomos guiados por visión.

El trabajo de Pomerleau (1988) representa otro avance clave, al introducir ALVINN, una red neuronal de tres capas que, entrenada con datos de video y telémetro láser, aprendía a seguir el camino sin intervención humana. Este enfoque destacó por su capacidad para manejar ruido y adaptarse a distintos escenarios, demostrando la utilidad de las redes neuronales en sistemas de control de navegación.

Complementando estos esfuerzos, Thorpe et al. (1988) documentaron el proyecto Navlab de Carnegie Mellon, que integraba visión computacional y control en tiempo real. A pesar de sus avances, identificaron limitaciones como la dependencia de entornos estructurados

y la falta de resiliencia ante la ausencia de señales externas, lo que evidenció la necesidad de sistemas de fusión sensorial.

Ya en los años 2000, Broggi et al. (2000) desarrollaron el vehículo autónomo ARGO, que recorrió 2000 km por autopistas europeas utilizando visión estereoscópica. Aunque exitoso, su funcionamiento dependía de condiciones climáticas favorables y carecía de soporte cartográfico, lo que subrayó la necesidad de tecnologías más robustas y adaptables.

Posteriormente, Collier et al. (2012) exploraron estrategias para entornos sin GPS, incluyendo técnicas como Visual Teach and Repeat y reconocimiento visual en convoyes, cruciales para operaciones autónomas en entornos militares. Wu et al. (2017) contribuyeron a mejorar la odometría visual urbana mediante la optimización de la detección de características y el seguimiento robusto en condiciones dinámicas, reduciendo la complejidad computacional sin sacrificar precisión.

Más recientemente, W. Chen et al. (2022) propusieron un sistema SLAM visual capaz de filtrar objetos en movimiento, enfrentando directamente una de las limitaciones históricas del SLAM tradicional, que asume entornos estáticos. Este desarrollo representa un paso significativo hacia sistemas de navegación verdaderamente autónomos y confiables en escenarios reales. En conjunto, estos trabajos muestran la evolución constante del campo hacia soluciones más inteligentes, resilientes y operativas en condiciones del mundo real.

Diversos trabajos recientes han explorado estrategias convergentes para abordar los desafíos de la navegación autónoma en vehículos aéreos no tripulados (UAVs), con un enfoque particular en simulación, percepción y control inteligente. En el campo de los entornos de prueba y simulación distribuida, Fabra et al. (2019) desarrollaron MBCAP, un protocolo que permite la evasión de colisiones de forma descentralizada en UAVs multirrotor con trayectorias previamente planificadas. A través del intercambio inalámbrico de trayectorias futuras, los drones pueden anticipar situaciones de riesgo y negociar de manera autónoma maniobras de evasión sin necesidad de un nodo de control centralizado. La extensión MBCAP-e introduce mejoras significativas al adaptar dinámicamente la distancia de seguridad y reducir la latencia, logrando una ejecución más fluida y eficiente. Ambos protocolos fueron validados en simuladores y pruebas de vuelo reales, demostrando robustez y bajo impacto operativo.

En el área de percepción visual en entornos cerrados, Grando et al. (2020) desarrollaron un dron autónomo capaz de operar íntegramente en interiores sin necesidad de GPS ni asistencia externa. El sistema emplea cámaras a bordo y procesamiento visual en tiempo real para navegación,

detección de zonas seguras de aterrizaje e inspección visual, incluyendo lectura de datos en entornos industriales simulados. Validado con éxito en escenarios reales, este dron obtuvo el primer puesto en la Brazil Open Flying Robot League 2019, destacándose por su precisión, estabilidad y autonomía.

La planificación de trayectorias mediante aprendizaje profundo ha sido explorada por Ramezani et al. (2023), quienes propusieron una arquitectura híbrida que integra un Control Predictivo de Modelos (MPC) impulsado por redes LSTM con el algoritmo de Aprendizaje por Refuerzo Profundo DDPG. Este modelo incorpora una "piscina de predicción" que almacena información prospectiva de estados y acciones, acelerando la convergencia del entrenamiento y reduciendo la tasa de fallos. Las simulaciones en entornos tridimensionales complejos mostraron una notable mejora en la evasión de obstáculos frente a enfoques tradicionales.

Con respecto al aterrizaje autónomo de UAVs, Polvara et al. (2017) desarrollaron un sistema jerárquico basado en Deep Q-Networks (DQN y Double DQN). El modelo fue entrenado en simuladores con imágenes de baja resolución orientadas hacia el suelo, y logró identificar marcadores visuales para maniobrar hacia ellos con precisión. Para incrementar la robustez frente a variabilidad ambiental, se utilizó la técnica de "domain randomization", obteniendo resultados comparables a los de operadores humanos. Complementariamente, He et al. (2020) propusieron un planificador local que combina Aprendizaje por Refuerzo Profundo (TD3) con aprendizaje por imitación a partir de datos expertos, permitiendo navegación reactiva y evasión de obstáculos en espacios tridimensionales utilizando cámaras de profundidad como principal sensor de percepción.

Finalmente, en un contexto aplicado a la conducción autónoma en autopistas, Baheri (2020) diseñó una arquitectura basada en Double Deep Q-Network (DDQN) con módulos de seguridad integrados. Uno de estos módulos es heurístico, con reglas rígidas de distanciamiento, y el otro dinámico, basado en una red neuronal recurrente de mezcla de densidades (MD-RNN), que predice múltiples trayectorias futuras para anticipar colisiones. Esta combinación permitió reducir significativamente los incidentes y mejorar la eficiencia operativa respecto a métodos convencionales.

En conjunto, estos trabajos reflejan una tendencia clara hacia sistemas de navegación cada vez más autónomos, adaptativos y capaces de operar con seguridad en entornos complejos, valiéndose de simulación avanzada, percepción inteligente y técnicas de aprendizaje profundo.

6. Informe de valor ético y social

El plan de tesis propone un sistema de navegación autónoma para drones urbanos basado en visión monocular y modelos de lenguaje pequeños (SLM), con énfasis en seguridad, eficiencia y accesibilidad. El proyecto se enfoca en resolver desafíos de navegación en entornos complejos como Buenos Aires, destacando su aporte al bien común mediante la reducción de riesgos, mejora en la seguridad pública y optimización de recursos en sectores como la logística, inspección industrial y agricultura. Su enfoque técnico permite transformar tareas peligrosas o lentas en operaciones automáticas y continuas, accesibles mediante hardware de bajo costo y software libre.

Desde una perspectiva ética y social, la tesis demuestra conciencia de los riesgos inherentes al uso de drones, abordando de forma activa la seguridad operacional, la ciberseguridad y la privacidad, especialmente mediante simulaciones en entornos digitales basados en datos públicos. Se destacan casos de uso en los que la intervención de drones autónomos evita la exposición humana a peligros en contextos como instalaciones nucleares, subestaciones eléctricas y terminales portuarias. Además, se subraya el potencial del sistema para asistir en emergencias, como incendios urbanos o forestales, sin comprometer vidas humanas.

La propuesta se alinea con el ideario de la Universidad Austral, integrando un enfoque centrado en la persona, la seguridad, el compromiso social y la sostenibilidad. Utiliza una arquitectura disruptiva que combina LLM y SLM para permitir una toma de decisiones adaptativa en misiones complejas, rompiendo con modelos clásicos como las FSM. El pipeline reproducible y abierto, junto con el uso de hardware económico, no solo promueve la democratización tecnológica, sino que contribuye a la formación, innovación y replicabilidad de soluciones en otros entornos.

Finalmente, el impacto positivo del proyecto en la sostenibilidad se observa en su aplicación a la agricultura de precisión, mejorando la eficiencia en el uso de insumos y reduciendo el daño ambiental. La autonomía de los drones optimiza procesos industriales al evitar pérdidas por fallos o ineficiencias. En conjunto, el trabajo representa un avance técnico con fuerte raíz ética y compromiso social, que transforma la manera en que se abordan desafíos urbanos, industriales y agrícolas, manteniendo como eje la seguridad humana, la accesibilidad y el uso responsable de la tecnología.

7. Metodología

El trabajo se enmarca en un tipo de estudio de desarrollo experimental y evaluación comparativa. Se busca desarrollar un pipeline completo para la navegación autónoma de drones en entornos urbanos simulados, e integrar un sistema con visión monocular para diversas aplicaciones. Además, se realiza una evaluación comparativa del Modelo de Lenguaje Ligerero (SLM) frente a Máquinas de Estados Finitos (FSM), analizando su desempeño en métricas clave en escenarios simulados.

El desarrollo y la validación se llevan a cabo en AirSim, un simulador basado en Unreal Engine. Se utiliza un entorno virtual 3D personalizado de Buenos Aires, generado a partir de RealityCapture, OpenStreet Maps y Blender. Las pruebas del sistema se realizarán emulando el comportamiento del Jetson Nano conectado a un dron en AirSim.

En el contexto de este trabajo, la "población" se refiere a los entornos urbanos simulados, específicamente Buenos Aires. Los "sujetos" de estudio son los cuadricópteros eVTOL y el hardware de bajo costo como Jetson Nano. No hay variables sociodemográficas aplicables, ya que el estudio no involucra sujetos humanos. La solución busca ser accesible y escalable para ciudades latinoamericanas.

No aplica directamente, ya que el estudio se enfoca en sistemas tecnológicos y entornos simulados, no en sujetos humanos.

Las métricas y factores clave para la evaluación del sistema se centran en diversos aspectos que reflejan tanto su desempeño operativo como su eficiencia técnica. En primer lugar, la tasa de éxito de misión es fundamental para medir la capacidad del sistema de completar las tareas asignadas sin fallos, lo cual refleja la robustez general en condiciones variables. El tiempo de reacción, entendido como la rapidez con la que el sistema responde a eventos o cambios en el entorno, es crucial para garantizar una navegación segura y efectiva, especialmente en escenarios dinámicos o con obstáculos imprevistos.

Desde el punto de vista técnico, el consumo computacional y el uso de memoria son indicadores esenciales para valorar la eficiencia del sistema, particularmente dado el objetivo de operar en hardware de bajo costo como el Jetson Nano. Estos parámetros determinan la viabilidad de desplegar la solución en dispositivos con recursos limitados sin comprometer su funcionalidad. La latencia de inferencia, que mide el retraso entre la entrada de datos y la generación de resultados por los modelos de inteligencia artificial, es otra métrica crítica, ya que influye directamente en la capacidad del sistema para procesar información en tiempo real y tomar decisiones oportunas.

Además, se realiza un análisis comparativo entre el Modelo de Aprendizaje Ligero (SLM) y las Máquinas de Estados Finitos (FSM), evaluando cuál de estos enfoques ofrece un mejor equilibrio entre precisión, velocidad y uso de recursos en la toma de decisiones. La eficacia de la visión monocular como principal sensor de percepción también es un punto de evaluación clave, considerando sus limitaciones y ventajas frente a otros sensores más costosos o complejos. Finalmente, la optimización específica para hardware accesible se analiza para asegurar que el sistema mantenga un rendimiento adecuado, permitiendo su aplicación práctica en entornos con restricciones económicas o de infraestructura tecnológica. En conjunto, estas métricas ofrecen un panorama integral que combina rendimiento operativo con eficiencia técnica, esencial para validar la solución propuesta.

El trabajo se organiza en dos pipelines principales que articulan la digitalización de entornos urbanos y la navegación dentro del simulador. En el primer pipeline, la digitalización comienza con la adquisición de datos mediante videos públicos de drones filmados en Buenos Aires y obtenidos de YouTube. Estos videos se someten a un proceso de preprocesamiento donde se extraen y filtran frames para asegurar una diversidad visual adecuada. Posteriormente, se realiza la anotación de los datos utilizando herramientas especializadas como LabelImg para la detección de obstáculos y LabelMe para la segmentación de zonas seguras de aterrizaje. A partir de esta información, se generan modelos 3D hiperrealistas mediante RealityCapture, los cuales son refinados con Blender para obtener representaciones más livianas que luego se cargan en el entorno de simulación AirSim.

El segundo pipeline está enfocado en la navegación dentro del simulador. En este, una companion computer basada en Jetson Nano se emula dentro de una imagen Docker y se conecta vía MAVLink a un lazo Software-in-the-Loop (SITL), que incluye un controlador de vuelo virtual PX4 también emulado en Docker. AirSim se encarga de proporcionar la simulación tanto del entorno 3D como de los sensores del dron, incluyendo cámara monocular, IMU y GPS. La companion computer simulada procesa en tiempo real estos datos a través de varios módulos clave. ORB-SLAM2 permite la construcción simultánea del mapa del entorno y la localización del dron, mientras que YOLO, en su versión YOLOv8n, detecta y clasifica obstáculos o puntos de interés a partir de las imágenes RGB capturadas por las cámaras simuladas. Paralelamente, MobileNetV3 junto con U-Net llevan a cabo la segmentación semántica para identificar zonas seguras destinadas al aterrizaje. Esta estructuración modular y secuencial de los pipelines facilita la integración entre la digitalización precisa del entorno y la navegación autónoma eficiente en un contexto simulado.

El análisis de datos se orientará a evaluar de forma comparativa el rendimiento de las distintas estrategias de control y los modelos de navegación implementados. Para ello, los resultados obtenidos por los módulos de SLAM y detección de objetos con YOLO se integrarán directamente en el pipeline de simulación, donde servirán como entradas para los sistemas de navegación basados en Máquinas de Estados Finitos (FSM), Modelos de Aprendizaje Ligerero (SLM) y, en una etapa posterior, Modelos de Lenguaje de gran escala (LLM).

La comparación entre el SLM y las FSM se realizará utilizando métricas clave que permitirán valorar su eficacia relativa en distintos escenarios. Entre estas métricas se consideran la tasa de éxito de las misiones, el tiempo de reacción ante eventos dinámicos del entorno y el consumo computacional necesario para mantener una operación fluida en condiciones de carga realista. Estas pruebas se desarrollarán en entornos simulados con complejidad progresiva, aprovechando las capacidades del sistema para evaluar comportamientos emergentes y adaptativos.

En cuanto a la planificación de trayectorias y puntos de control (waypoints), se explorará la capacidad de los LLM para generar rutas y comandos en lenguaje natural, evaluando su integración fluida con los sistemas autónomos. Esta incorporación apunta a ampliar la interfaz hombre-máquina hacia formas más intuitivas de operación, especialmente útiles en misiones complejas o con operadores no especializados.

Aunque la validación en hardware real queda fuera del alcance inmediato de esta fase del proyecto, se anticipa como un paso crítico en la evolución del sistema. Esta validación implicará desplegar el sistema en una placa Jetson Nano conectada a un dron físico, donde se podrán registrar métricas reales de desempeño, tales como la latencia de inferencia, el consumo de recursos computacionales (medido en fotogramas por segundo procesados) y el uso de memoria efectiva. Estos resultados permitirán contrastar los valores obtenidos en simulación con condiciones reales de operación, revelando posibles discrepancias y áreas de mejora necesarias para una implementación robusta en campo. Así, el análisis de datos no se limita a una validación técnica, sino que busca sentar las bases para una transición efectiva hacia aplicaciones prácticas con impacto directo en el terreno.

Las limitaciones del presente trabajo se enmarcan en decisiones deliberadas para acotar el alcance a un entorno de desarrollo realista pero controlado. El sistema se basa exclusivamente en datos públicos, concretamente videos capturados por drones en Buenos Aires disponibles en YouTube, los cuales sirven como base para la generación de escenarios virtuales utilizados durante la simulación. Esta elección busca garantizar accesibilidad y reproducibilidad, pero implica que no se trabaja con datos propios o específicamente capturados para los fines de la investigación.

Todo el proceso de entrenamiento y validación se lleva a cabo en entornos virtuales, utilizando el simulador AirSim como plataforma principal para emular las condiciones operativas del sistema. Esta virtualización abarca tanto los componentes del entorno como el comportamiento de hardware específico, como es el caso de la emulación de una Jetson Nano. De este modo, las pruebas se orientan a evaluar el desempeño del sistema tal como funcionaría en una placa de bajo costo conectada a un dron, pero sin involucrar aún un despliegue en hardware físico real.

En esta etapa del proyecto se aborda un conjunto acotado de tareas principales, centradas en la detección de obstáculos mediante el uso de modelos como YOLO, la segmentación semántica del terreno para identificar zonas seguras de aterrizaje, y la construcción simultánea de mapas junto con la localización del vehículo mediante ORB-SLAM2. Estas capacidades permiten validar la viabilidad técnica del enfoque, aunque no abarcan aún aspectos como la navegación en enjambre o la integración de sensores adicionales.

La validación sobre hardware físico, particularmente sobre una placa Jetson Nano conectada como computadora auxiliar (companion computer) a un dron real, se contempla como una fase futura. Esta etapa permitirá contrastar las condiciones ideales de simulación con el comportamiento real del sistema bajo limitaciones físicas concretas, como latencias, fluctuaciones en la calidad de sensores, consumo energético y capacidad de cómputo limitada. La implementación práctica permitirá evaluar con mayor precisión la robustez de las optimizaciones propuestas y detectar posibles desajustes entre el entorno virtual y el mundo físico, fundamentales para una futura adopción del sistema en misiones reales.

Referencias

- Alarm as estate agent's drone crashes into house - Property Industry Eye.*
(s. f.). Recuperado 29 de junio de 2025, de
https://propertyindustryeye.com/alarm-as-estate-agents-drone-crashes-into-house/?utm_source=chatgpt.com
- Aldao, E., González-de Santos, L. M., & González-Jorge, H. (2022). LiDAR Based Detect and Avoid System for UAV Navigation in UAM Corridors. *Drones*, 6(8). <https://doi.org/10.3390/drones6080185>
- Aliane, N. (2024). A Survey of Open-Source UAV Autopilots. *Electronics*, 13(23). <https://doi.org/10.3390/electronics13234785>
- Arnold, R., Yamaguchi, H., & Tanaka, T. (2018). Search and rescue with autonomous flying robots through behavior-based cooperative intelligence. *Journal of International Humanitarian Action*, 3. <https://doi.org/10.1186/s41018-018-0045-4>
- Broggi, A., Bertozzi, M., Fascioli, A., Guarino, C., Guarino Lo Bianco, C., & Piazzzi, A. (2000). The Argo Autonomous Vehicle's Vision And Control Systems. *Int. J. Intelligent. Control. Syst.*, 3.
- Cangahuala, L. A., Campagnola, S., Bradley, B. K., Boone, D. R., Buffington, B. B., Ludwinski, J. M., Nandi, S., & Scott, C. J. (2025). Europa Clipper Mission Design, Mission Plan, and Navigation. *Space Science Reviews*, 221(1), 22. <https://doi.org/10.1007/s11214-025-01140-2>
- Castelli, T., Sharghi, A., Harper, D., Trémeau, A., & Shah, M. (2016). Autonomous navigation for low-altitude UAVs in urban areas. *CoRR*, abs/1602.08141. <http://arxiv.org/abs/1602.08141>
- Castro, W., Marcato Junior, J., Polidoro, C., Osco, L. P., Gonçalves, W., Rodrigues, L., Santos, M., Jank, L., Barrios, S., Valle, C., Simeão, R., Carromeu, C., Silveira, E., Jorge, L. A. de C., & Matsubara, E. (2020). Deep Learning Applied to Phenotyping of Biomass in Forages with UAV-Based RGB Imagery. *Sensors*, 20(17). <https://doi.org/10.3390/s20174802>
- Chahine, M., Hasani, R., Kao, P., Ray, A., Shubert, R., Lechner, M., Amini, A., & Rus, D. (2023). Robust flight navigation out of distribution with liquid neural networks. *Science Robotics*, 8(77). <https://doi.org/10.1126/scirobotics.adc8892>
- Chen, F., Wu, Q., Tao, G., & Jiang, B. (2014). A Reconfiguration Control Scheme for a Quadrotor Helicopter via Combined Multiple Models. *International Journal of Advanced Robotic Systems*, 11(8), 122. <https://doi.org/10.5772/58833>
- Chen, W., Shang, G., Hu, K., Zhou, C., Wang, X., Fang, G., & Ji, A. (2022). A Monocular-Visual SLAM System with Semantic and Optical-Flow Fusion for Indoor Dynamic Environments. *Micromachines*, 13(11). <https://doi.org/10.3390/mi13112006>
- Collier, J., Trentini, M., Giesbrecht, J., Mcmanus, C., Furgale, P., Stenning, B., Barfoot, T., Se, S., Kotamraju, V., Jasiobedzki, P., Shang, L., Chan, B., Harmat, A., & Sharf, I. (2012, enero). Autonomous Navigation and Mapping

-
- in GPS-Denied Environments at Defence R&D Canada. *NATO Symposium SET 168: Navigation Sensor and Systems in GNSS Denied Environments*.
- Da Silva, A., Fernández, S., Vidal, B., Sodre, H., Moraes, P., Peters, C., Barcelona, S., Sandin, V., Moraes, W., Mazondo, A., Macedo, B., Assunção, N., de Vargas, B., Kelbouscas, A., & Grando, R. (2024). *Implementación de Navegación en Plataforma Robótica Móvil Basada en ROS y Gazebo*. <http://arxiv.org/abs/2410.19972>
- Dickmanns, E. D. (2024). Evolution of the “4-D Approach” to Dynamic Vision for Vehicles. *Electronics*, 13(20), 4133.
- Drone Silo Inspections - Case Study - Horus Drones*. (s. f.). Recuperado 29 de junio de 2025, de https://horusdrones.com/home/drone-insights/case-studies/drone-silo-inspection/?utm_source=chatgpt.com
- Giacomossi Jr, L., Maximo, M., Sundelius, N., Funk, P., Brancalion, J. F. B., & Sohlberg, R. (2024). *Cooperative Search and Rescue with Drone Swarm* (pp. 381-393). https://doi.org/10.1007/978-3-031-39619-9_28
- Goel, A., Tung, C., Hu, X., Thiruvathukal, G. K., Davis, J. C., & Lu, Y.-H. (2021). Efficient Computer Vision on Edge Devices with Pipeline-Parallel Hierarchical Neural Networks. *CoRR*, *abs/2109.13356*. <https://arxiv.org/abs/2109.13356>
- Graf, M., Speidel, O., Ruof, J., & Dietmayer, K. (2021). *On-Road Motion Planning for Automated Vehicles at Ulm University*. <http://arxiv.org/abs/2012.04028>
- Hoang, V. D., Nyboe, F. F., Malle, N. H., & Ebeid, E. (2024). *Autonomous Overhead Powerline Recharging for Uninterrupted Drone Operations*. <https://arxiv.org/abs/2403.06533>
- Hu, J., Ren, Z., & Cheng, W. (2024). *Finite State Machines-Based Path-Following Collaborative Computing Strategy for Emergency UAV Swarms*. <https://arxiv.org/abs/2407.11531>
- Hughes, M., & Engelbrecht, J. (2023). Autonomous navigation for multiple unmanned aerial vehicles (UAVs) in urban environments. *MATEC Web of Conferences*, 388. <https://doi.org/10.1051/mateconf/202338804011>
- Hwang, J.-J., Xu, R., Lin, H., Hung, W.-C., Ji, J., Choi, K., Huang, D., He, T., Covington, P., Sapp, B., Zhou, Y., Guo, J., Anguelov, D., & Tan, M. (2024). *EMMA: End-to-End Multimodal Model for Autonomous Driving*. <https://arxiv.org/abs/2410.23262>
- Infocampo. (s. f.). *Renova amplió su planta de procesamiento y construirá una nueva terminal en Timbués*. INFOCAMPO Noticias del campo en el momento justo. Recuperado 25 de junio de 2025, de <https://www.infocampo.com.ar/renova-amplio-su-planta-de-procesamiento-y-construira-una-nueva-terminal-en-timbues/#:~:text=Para%20su%20operaci%C3%B3n%2C%20una%20vez,390%20personas%20actuales%20a%20640>.
- Kemeny, A., & Panerai, F. (2003). Evaluating perception in driving simulation experiments. *Trends in Cognitive Sciences*, 7(1), 31-37. [https://doi.org/10.1016/S1364-6613\(02\)00011-6](https://doi.org/10.1016/S1364-6613(02)00011-6)

-
- Koubaa, A., Allouch, A., Alajlan, M., Javed, Y., Belghith, A., & Khalgui, M. (2019). Micro Air Vehicle Link (MAVLink) in a Nutshell: A Survey. *CoRR*, *abs/1906.10641*. <http://arxiv.org/abs/1906.10641>
- Langåker, H.-A., Kjerkreit, H., Syversen, C. L., Moore, R. J. D., Holhjem, Ø. H., Jensen, I., Morrison, A., Transeth, A. A., Kvien, O., Berg, G., Olsen, T. A., Hatlestad, A., Negård, T., Broch, R., & Johnsen, J. E. (2021). An autonomous drone-based system for inspection of electrical substations. *International Journal of Advanced Robotic Systems*, *18*(2), 17298814211002972. <https://doi.org/10.1177/17298814211002973>
- Li, Q., Yu, W., & Jiang, S. (2022). *Optimized Views Photogrammetry: Precision Analysis and A Large-scale Case Study in Qingdao*. <https://arxiv.org/abs/2206.12216>
- Madridano Carrasco, Á. (2020). *Arquitectura de software para navegación autónoma y coordinada de enjambres de drones en labores de lucha contra incendios forestales y urbanos* [Tesis doctoral, Universidad Carlos III de Madrid]. <https://hdl.handle.net/10016/32463>
- Marazzato, R., & Sparavigna, A. C. (2015). Retinex filtering of foggy images: generation of a bulk set with selection and ranking. *CoRR*, *abs/1509.08715*. <http://arxiv.org/abs/1509.08715>
- Martin, P. G., Scott, T. B., Payton, O. D., & Fardoulis, J. S. (2017). *High-Resolution Aerial Radiation Mapping for Nuclear Decontamination and Decommissioning-17371*.
- Matej, J. (2016). *Simulation of vehicle in Unreal Game Engine using equations of motion, Runge-Kutta and line tracing methods to solve motion and scan Unreal Engine terrain under wheel*. Publishing House at the Technical University in Zvolen . <https://doi.org/10.5281/zenodo.55806>
- Miranda, V., Rezende, A., Rocha, T., Azpúrua, H., Pimenta, L., & Freitas, G. (2021). Autonomous Navigation System for a Delivery Drone. *Journal of Control, Automation and Electrical Systems*, *33*. <https://doi.org/10.1007/s40313-021-00828-4>
- Mur-Artal, R., Montiel, J. M. M., & Tardós, J. D. (2015). ORB-SLAM: a Versatile and Accurate Monocular SLAM System. *CoRR*, *abs/1502.00956*. <http://arxiv.org/abs/1502.00956>
- Nguyen, D. D., Rohacs, J., & Rohacs, D. (2021). Autonomous Flight Trajectory Control System for Drones in Smart City Traffic Management. *ISPRS International Journal of Geo-Information*, *10*(5). <https://doi.org/10.3390/ijgi10050338>
- Nothdurft, T., Hecker, P., Ohl, S., Saust, F., Maurer, M., Reschka, A., & Rüdiger Böhmer, J. (2011). *Stadtpilot: First Fully Autonomous Test Drives in Urban Traffic*. https://www.tu-braunschweig.de/fileadmin/Redaktionsgruppen/Institute_Fakultaet_5/IFR/Daten_EFS/Publikationen/Stadtpilot_FirstFullyAutonomous.pdf
- NVIDIA. (2025). *Jetson Nano Brings the Power of Modern AI to Edge Devices*. <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-nano/product-development/>

-
- Open Source Autopilot for Drones - PX4 Autopilot*. (s. f.). Recuperado 29 de junio de 2025, de <https://px4.io/>
- Pestana Puerta, J. (2017). *Vision-Based Autonomous Navigation of Multirotor Micro Aerial Vehicles* [PhD Thesis, Universidad Politécnica de Madrid]. <https://doi.org/10.20868/UPM.thesis.47726>
- Pomerleau, D. A. (1988). ALVINN: An Autonomous Land Vehicle in a Neural Network. En D. Touretzky (Ed.), *Advances in Neural Information Processing Systems* (Vol. 1). Morgan-Kaufmann. https://proceedings.neurips.cc/paper_files/paper/1988/file/812b4ba287f5ee0bc9d43bbf5bbe87fb-Paper.pdf
- Redmon, J., Divvala, S. K., Girshick, R. B., & Farhadi, A. (2015). You Only Look Once: Unified, Real-Time Object Detection. *CoRR*, *abs/1506.02640*. <http://arxiv.org/abs/1506.02640>
- Resolución ANAC - Reglamento de Vehículos Aéreos No tripulados, Pub. L. No. 880/2019 (2019). <https://www.argentina.gob.ar/normativa/nacional/resoluci%C3%B3n-880-2019-333259>
- Samy, M., Amer, K., Shaker, M., & ElHelw, M. (2019). *Drone Path-Following in GPS-Denied Environments using Convolutional Networks*. <https://arxiv.org/abs/1905.01658>
- Shah, S., Dey, D., Lovett, C., & Kapoor, A. (2017). *AirSim: High-Fidelity Visual and Physical Simulation for Autonomous Vehicles*. <http://arxiv.org/abs/1705.05065>
- Shin, Y.-S., & Kim, A. (2019). Sparse Depth Enhanced Direct Thermal-infrared SLAM Beyond the Visible Spectrum. *IEEE Robotics and Automation Letters*, *4*(3), 2918-2925. <https://arxiv.org/abs/1902.10892>
- Song, C., Guo, X., & Sui, J. (2025). Improved Model Predictive Control Algorithm for the Path Tracking Control of Ship Autonomous Berthing. *Journal of Marine Science and Engineering*, *13*(7). <https://doi.org/10.3390/jmse13071273>
- Thorpe, C., Hebert, M. H., Kanade, T., & Shafer, S. A. (1988). Vision and navigation for the Carnegie-Mellon Navlab. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, *10*(3), 362-373. <https://doi.org/10.1109/34.3900>
- Turco, L., Zhao, J., Xu, Y., & Tsourdos, A. (2024). A Study on Co-simulation Digital Twin with MATLAB and AirSim for Future Advanced Air Mobility. *2024 IEEE Aerospace Conference*, 1-18. <https://doi.org/10.1109/AERO58975.2024.10521333>
- UMILES GROUP. (2024, diciembre 20). *LiDAR y Fotogrametría: Las armas secretas de los drones en la topografía moderna*. https://umilesgroup.com/drones-lidar-y-fotogrametria-cambiando-la-topografia-moderna/#Mediciones_precisas_de_areas_y_volumenes
- Vipparla, C., Krock, T., Nouduri, K., Fraser, J., AliAkbarpour, H., Sagan, V., Cheng, J.-R. C., & Kannappan, P. (2024). Fusion of Visible and Infrared

-
- Aerial Images from Uncalibrated Sensors Using Wavelet Decomposition and Deep Learning. *Sensors*, 24(24). <https://doi.org/10.3390/s24248217>
- Wahba, G. (1965). A Least Squares Estimate of Satellite Attitude. *SIAM Review*, 7(3), 409. <https://doi.org/10.1137/1007077>
- Wu, M., Lam, S.-K., & Srikanthan, T. (2017). A Framework for Fast and Robust Visual Odometry. *IEEE Transactions on Intelligent Transportation Systems*, 18(12), 3433-3448. <https://doi.org/10.1109/TITS.2017.2685433>
- X500 V2 Kits – Holybro Store. (s. f.). Recuperado 29 de junio de 2025, de https://holybro.com/products/x500-v2-kits?srltid=AfmBOopnIEH3FTOfmnWNP4_U-FeQkTac6GR6Xa2hSiZ6km9mnjhkf8zT
- Xu, Y., Liu, Y., Li, H., Wang, L., & Ai, J. (2024). A Deep Learning Approach of Intrusion Detection and Tracking with UAV-Based 360° Camera and 3-Axis Gimbal. *Drones*, 8(2). <https://doi.org/10.3390/drones8020068>
- Yang, C., Zhou, H., Liu, X., Ke, Y., Gao, B., Grzegorzec, M., Boukhers, Z., Chen, T., & See, J. (2025). BladeView: Toward Automatic Wind Turbine Inspection With Unmanned Aerial Vehicle. *IEEE Transactions on Automation Science and Engineering*, 22, 7530-7545. <https://doi.org/10.1109/TASE.2024.3464640>
- Zhou, Y., Bautista, J., Yao, W., & de Marina, H. G. (2025). *Inverse Kinematics on Guiding Vector Fields for Robot Path Following*. <https://arxiv.org/abs/2502.17313>
- Zhu, Y., Moniz, J. R. A., Bhargava, S., Lu, J., Piraviperumal, D., Li, S., Zhang, Y., Yu, H., & Tseng, B.-H. (2024). *Can Large Language Models Understand Context?* <https://arxiv.org/abs/2402.00858>